

Inferencia Bayesiana

Una Herramienta para el Análisis de Datos

Notas del curso, UNAM Agosto-Diciembre 2025

Autor: Imelda Trejo

14 de agosto de 2025

Resumen

Estas notas introducen los fundamentos de la inferencia bayesiana para estudiantes de maestría y doctorado en matemáticas del Centro de Ciencias Matemáticas, UNAM Morelia. Cubrimos desde los conceptos filosóficos fundamentales hasta las bases matemáticas rigurosas, incluyendo espacios muestrales, distribuciones de probabilidad, el teorema de Bayes y el concepto de intercambiabilidad.

Índice

1. Contexto Histórico	3
2. Introducción a la Estadística e Inferencia Estadística	4
2.1. ¿Qué es la estadística?	4
2.2. Una Distinción Fundamental: Interpretación vs. Explicación	4
2.3. Por qué importa esta distinción	5
2.4. Incertidumbre en Estadística	5
2.4.1. Cuantificación de la Incertidumbre	6
2.5. El Paradigma Bayesiano	6
2.6. Introducción al análisis de datos	6
2.6.1. Conceptos fundamentales	6
2.6.2. Clasificación de variables	8
2.6.3. La función <code>class()</code> en R	10
2.7. Ejercicios de cómputo	11

3. Fundamentos Matemáticos	11
3.1. Espacios Muestrales y Eventos	11
3.2. Particiones	12
3.3. Variables Aleatorias	12
3.4. Funciones de Probabilidad	12
3.5. Distribuciones Discretas Importantes	13
3.5.1. Distribución Bernoulli	13
3.5.2. Distribución Binomial	13
3.5.3. Distribución Poisson	13
3.5.4. Distribución Binomial Negativa	13
3.6. Distribuciones Continuas Importantes	13
3.6.1. Distribución Beta	13
3.6.2. Distribución Gamma	14
3.6.3. Distribución Normal	14
3.6.4. Distribución Log-Normal	14
4. La Regla de Bayes: El Fundamento	14
4.1. Probabilidad Condicional	14
4.2. Teorema de Bayes	14
4.3. Inferencia Estadística Bayesiana	15
4.4. Proceso de Aprendizaje Bayesiano	15
5. Intercambiabilidad	16
5.1. Definición e Intuición	16
5.2. Teorema de De Finetti	16
5.3. Implicaciones Prácticas	16
6. Resumen y Próximos Pasos	16

1. Contexto Histórico

El término de inferencia Bayesiana es en honor a Thomas Bayes.



Figura 1: Esta es probablemente la única imagen que se tiene de Thomas Bayes, imagen obtenida de https://en.wikipedia.org/wiki/Thomas_Bayes

Thomas Bayes (1701-1761) fue un matemático y estadístico inglés que formuló el **teorema de Bayes**, una regla fundamental en estadística y aprendizaje automático moderno. Su trabajo dio origen a toda un área de la estadística: la **estadística bayesiana**, que se centra en determinar la probabilidad de un evento basándose en el conocimiento previo de condiciones que puedan estar relacionadas con dicho evento. Esto es, para dos eventos A y B con, $\mathbb{P}(B) > 0$:

$$\mathbb{P}(A | B) = \frac{\mathbb{P}(B | A)\mathbb{P}(A)}{\mathbb{P}(B)}$$

Aquí, el evento A no lo conocemos con precisión, pero creemos que este evento tiene una distribución $\mathbb{P}(A)$, que también se le conoce como *distribución a priori*. Luego, la probabilidad de A se actualiza al conocer la relación entre los eventos A y B . Siendo, $\mathbb{P}(A | B)$ la *distribución posterior*, distribución que resulta al incorporar los nuevos conocimientos sobre el evento A .

En nuestro contexto estimaremos el parámetro θ dado datos:

$$\mathbb{P}(\theta | \text{Datos}) = \frac{\mathbb{P}(\text{Datos} | \theta)\pi(\theta)}{\mathbb{P}(\text{Datos})}$$

El teorema de Bayes proporciona un marco matemático para actualizar nuestras creencias (falta de conocimientos) sobre cantidades inciertas a medida que observamos nuevos datos—un proceso que refleja cómo progresa el conocimiento científico.

2. Introducción a la Estadística e Inferencia Estadística

2.1. ¿Qué es la estadística?

La estadística es la ciencia que **recopila, organiza, analiza e interpreta datos** para entender fenómenos y ayudar en la toma de decisiones. Podemos dividirla en dos ramas principales:

- **Estadística descriptiva:** Resume y describe los datos mediante tablas, gráficas y medidas como media, mediana y varianza.
- **Estadística inferencial:** Utiliza datos **muestrales** para hacer **inferencias** sobre una **población** o proceso subyacente.

2.2. Una Distinción Fundamental: Interpretación vs. Explicación

“La estadística debe considerarse una interpretación de los fenómenos naturales, más que una explicación.”

Esta afirmación destaca un concepto crucial:

- La **estadística no explica por qué ocurre algo**; en cambio, **resume lo que observamos y cuantifica la incertidumbre** en nuestras observaciones. La forma de cuantificar la incertidumbre es con probabilidades.
- La **estadística** nos dice: *“Dadas estas observaciones, así es como se comportan los datos, y esta es la probabilidad de que este patrón sea real.”*
- La **explicación** (el “por qué”) típicamente proviene de una **teoría científica o modelo causal**.

Ejemplo 2.1. Patrones de influenza estacional.

- **Fenómeno:** “Los casos de gripe aumentan durante el invierno.”
- **Análisis estadístico:** Analiza datos históricos, calcula aumentos promedio, estima probabilidades de brotes.
- **Explicación científica:** “El virus sobrevive mejor a temperaturas frías, y las personas pasan más tiempo en espacios cerrados en proximidad.”

2.3. Por qué importa esta distinción

Confundir interpretación estadística con explicación causal lleva a:

1. Creer que correlación implica causalidad
2. Aplicar incorrectamente resultados estadísticos fuera de su contexto científico
3. Ignorar que la estadística **depende de la calidad y representatividad de los datos**

Ejemplo 2.2 (Ejemplo clásico). Las ventas de helado y los incidentes de ahogamiento muestran correlación positiva.

- **Observación estadística:** Cuando aumentan las ventas de helado, también aumentan los ahogamientos.
- **Inferencia causal incorrecta:** El helado causa ahogamientos.
- **Explicación real:** El calor es la causa común—en verano, más gente compra helado y más gente va a nadar, resultando en más ahogamientos.

2.4. Incertidumbre en Estadística

La **incertidumbre** representa **lo que no sabemos con certeza** sobre un fenómeno o valor de parámetro. En modelado matemático y análisis de datos, la incertidumbre surge de:

1. **Errores de medición** en la recolección de datos
2. **Variabilidad natural** en los fenómenos
3. **Observaciones limitadas**—observamos muestras, no poblaciones completas

4. **Limitaciones muestrales**—muestras pequeñas o no representativas
5. **Inadecuación del modelo**—los modelos son simplificaciones de la realidad
6. **Ruido en los datos**—fluctuaciones aleatorias en las mediciones

2.4.1. Cuantificación de la Incertidumbre

La estadística **cuantifica** esta incertidumbre mediante diferentes enfoques:

- **Enfoque frecuentista:** Intervalos de confianza, valores p
- **Enfoque bayesiano:** Distribuciones posteriores, intervalos creíbles

2.5. El Paradigma Bayesiano

Principio bayesiano fundamental: Cualquier cantidad que no conocemos con certeza (ya sea un parámetro, resultado futuro, o proceso no observado) se representa mediante una **distribución de probabilidad**.

Esta representación probabilística nos permite:

- Expresar grados de conocimiento sobre cantidades desconocidas
- Actualizar estos conocimientos conforme nuevos datos se vuelven disponibles
- Hacer predicciones con incertidumbre cuantificada

Usando la distribución de probabilidad es fácil calcular predicciones con intervalos de credibilidad, ver Figura 2.

2.6. Introducción al análisis de datos

Tarea: Leer el capítulo 1 del libro [1]

A continuación se presenta un resumen del capítulo.

2.6.1. Conceptos fundamentales

El análisis de datos es una disciplina que nos permite extraer información significativa de conjuntos de observaciones. Para comprender esta disciplina, es esencial dominar algunos conceptos básicos que forman la base de todo estudio estadístico.




Figura 2: Distribución Normal estándar: $\mu = 0$, $\sigma = 1$.

Definiciones básicas

Definición 2.1 (Población). Una población es un conjunto de personas, objetos o eventos, de los cuales nos interesa estudiar algunas de sus características.

Definición 2.2 (Muestra). Una muestra es cualquier subconjunto de una población.

Definición 2.3 (Variable). Una variable es una característica de interés que posee cada elemento de una población y que podemos medir o registrar.

Una variable también puede considerarse como una pregunta que se le hace a cada elemento de la población, produciendo una respuesta en cada caso.

Ejemplo: En una población humana, podemos considerar la variable o pregunta: “¿Eres estudiante?” y obtener como respuesta “sí” o “no”.

Definición 2.4 (Datos). Mediante el término datos se entiende al conjunto de observaciones de una o varias variables de interés para todos los elementos de una muestra.

Generalmente, un conjunto de datos se organiza y almacena en una computadora en la forma de un arreglo bidimensional o tabla, donde las filas representan las observaciones (elementos de la muestra) y las columnas representan las variables.

Ejemplo de organización de datos Consideremos un estudio sobre estudiantes universitarios. La siguiente tabla muestra cómo se organizarían los datos:

ID	Edad	Sexo	Carrera	Promedio
1	20	Masculino	Ingeniería	8.5
2	19	Femenino	Medicina	9.2
3	21	Masculino	Derecho	7.8
4	22	Femenino	Psicología	8.9
5	20	Femenino	Ingeniería	8.1

Tabla 1: Ejemplo de organización de datos en forma tabular

2.6.2. Clasificación de variables

En el análisis de datos, es fundamental entender el tipo de variable con la que se trabaja, ya que esto determina qué métodos estadísticos son adecuados para su análisis. Las variables se clasifican principalmente en dos grandes categorías: cuantitativas y cualitativas.

Variables cuantitativas

Definición 1.5 (Variable cuantitativa): Una variable es cuantitativa si sus valores son números y representan una cantidad.

Las variables cuantitativas se subdividen en:

- **Discretas:** Toman valores enteros o contables. Ejemplos: número de hijos en una familia, número de automóviles vendidos, cantidad de libros en una biblioteca.
- **Continuas:** Pueden tomar cualquier valor dentro de un intervalo. Ejemplos: estatura, peso, longitud de un tornillo, temperatura.

Características de las variables cuantitativas:

- Permiten calcular promedios, varianzas y otras medidas estadísticas.
- Se pueden aplicar técnicas estadísticas (estimación de parámetros usando Poisson) paramétricas.
- Tienen sentido las operaciones aritméticas (suma, resta, multiplicación, división).
- Poseen un orden natural y distancias medibles entre valores.

Variables cualitativas (categóricas)

Definición 2.5 (Variable cualitativa). Una variable es cualitativa si sus valores representan una cualidad, un atributo o una categoría. Se les llama también variables categóricas.

Las variables cualitativas se caracterizan por:

- Tomar valores en un conjunto limitado de categorías.
- Pueden o no tener un orden natural.
- Se utilizan para clasificar observaciones en grupos.

Las variables cualitativas se subdividen en:

- **Nominales:** No tienen un orden natural entre sus categorías.
- **Ordinales:** Sus categorías tienen un orden natural o jerárquico.
- **Binarias o dicotómicas:** Caso especial que toma exactamente dos valores.

Ejemplos de variables cualitativas:

- **Nominales:**
 - Grupo sanguíneo: A, B, AB, O
 - Estado civil: soltero, casado, divorciado, viudo
 - Color de ojos: azul, marrón, verde
 - Nacionalidad: mexicana, estadounidense, canadiense
- **Ordinales:**
 - Nivel educativo: primaria, secundaria, preparatoria, universidad
 - Calificación: excelente, bueno, regular, malo
 - Grupos de edad: joven, adulto, mayor
- **Binarias o dicotómicas:**
 - Sexo: masculino o femenino
 - Respuesta: sí o no
 - Presencia de enfermedad: presente o ausente
 - Estado de empleo: empleado o desempleado

Importancia de la clasificación La correcta identificación del tipo de variable es crucial porque:

- **Determinación de técnicas estadísticas:** La naturaleza de la variable (numérica o categórica) determina qué pruebas y medidas pueden aplicarse.
 - Variables numéricas: pruebas paramétricas, correlaciones, regresión, etc.
 - Variables categóricas: pruebas de proporciones, chi-cuadrada, etc.
- **Influencia en la presentación:** El tipo de variable define el tipo de gráfico apropiado.
 - Categóricas: diagramas de barras, diagramas de pastel.
 - Numéricas: histogramas, diagramas de caja (*boxplots*), funciones de densidad.
- **Interpretación de resultados:** Una media tiene sentido para variables numéricas, pero no para categóricas nominales.
- **Selección de medidas de tendencia central y dispersión:**
 - Numéricas: media, mediana, moda, desviación estándar, varianza, percentiles, cuartiles.
 - Categóricas: moda, frecuencias absolutas y relativas, porcentajes.

2.6.3. La función `class()` en R

Devuelve el **tipo de dato** que R asigna a un objeto, indicando cómo R interpreta la variable y qué operaciones son posibles.

Tabla 2: Tipos de datos más comunes en R según `class()`

Tipo de dato	Descripción	Ejemplo
numeric	Números reales (decimales)	3.14
integer	Números enteros	42L
character	Texto	"Hola"
logical	Valores verdadero/falso	TRUE
factor	Variable categórica con niveles	<code>factor(c('A','B'))</code>
Date	Fechas	<code>as.Date("2025-08-12")</code>

2.7. Ejercicios de cómputo

Las bases de datos se encuentran en

https://github.com/imelit/Bayesian_inference_class_2025/tree/main

Asignación

- ¿Qué tipo de variables son edad, sexo, comorbidades? Cuantos tipo de enfermedades respiratorias son reportados?
item cuantos tipos de influenza hay? realiza una gráfica de barras para comparar estas, cual es el más prevalente en la muestra, total o en un tiempo específico?
- De entre los casos reportados por Flu. Realiza una gráfica de barras del total de casos por flu estratificado por meses, partiendo de octubre a mayo, tempora de influenza, <https://www.cdc.gov/flu/about/season.html>.
- Visualiza la serie de tiempo de Influenza estratificado por grupos de edad (casos contra tiempo).
- ¿Cómo las comorbidades se relacionan con influenza?
Guía para el análisis:
<https://www.cdc.gov/fluview/overview/fluview-interactive.html>

3. Fundamentos Matemáticos

3.1. Espacios Muestrales y Eventos

Definición 3.1 (Espacio Muestral). El espacio muestral Ω es el conjunto de todos los posibles resultados de un experimento aleatorio.

Definición 3.2 (Evento). Un evento A es un subconjunto del espacio muestral Ω .

Definición 3.3 (σ -álgebra). Una colección \mathcal{F} de subconjuntos de Ω es una σ -álgebra si:

1. $\Omega \in \mathcal{F}$
2. Si $A \in \mathcal{F}$, entonces $A^c \in \mathcal{F}$
3. Si $A_1, A_2, \dots \in \mathcal{F}$, entonces $\bigcup_{i=1}^{\infty} A_i \in \mathcal{F}$

3.2. Particiones

Definición 3.4 (Partición). Una colección de eventos $\{B_1, B_2, \dots, B_k\}$ forma una partición de Ω si:

1. $B_i \cap B_j = \emptyset$ para $i \neq j$ (mutuamente excluyentes)
2. $\bigcup_{i=1}^k B_i = \Omega$ (exhaustivos)
3. $\mathbb{P}(B_i) > 0$ para todo i

Las particiones son fundamentales en análisis bayesiano para aplicar la ley de probabilidad total.

3.3. Variables Aleatorias

Definición 3.5 (Variable Aleatoria). Una variable aleatoria X es una función medible $X : \Omega \rightarrow \mathbb{R}$.

Definición 3.6 (Variable Aleatoria Discreta). X es discreta si toma valores en un conjunto contable.

Definición 3.7 (Variable Aleatoria Continua). X es continua si existe una función $f(x) \geq 0$ tal que

$$\mathbb{P}(a < X \leq b) = \int_a^b f(x) dx$$

para todo $a < b$.

3.4. Funciones de Probabilidad

Para variables aleatorias discretas, la **función de masa de probabilidad (FMP)** es:

$$\mathbb{P}(X = x) = p(x), \quad \text{donde} \quad \sum_x p(x) = 1$$

Para variables aleatorias continuas, la **función de densidad de probabilidad (FDP)** satisface:

$$\int_{-\infty}^{\infty} f(x) dx = 1$$

3.5. Distribuciones Discretas Importantes

3.5.1. Distribución Bernoulli

Definición 3.8 (Distribución Bernoulli). $X \sim \text{Bernoulli}(\theta)$ si $X \in \{0, 1\}$ con $\mathbb{P}(X = 1) = \theta$.

FMP: $p(x) = \theta^x(1 - \theta)^{1-x}$ para $x \in \{0, 1\}$

Propiedades: $\mathbb{E}[X] = \theta$, $\text{Var}(X) = \theta(1 - \theta)$

3.5.2. Distribución Binomial

Definición 3.9 (Distribución Binomial). $X \sim \text{Binomial}(n, \theta)$ representa el número de éxitos en n ensayos independientes Bernoulli(θ).

FMP: $p(x) = \binom{n}{x} \theta^x (1 - \theta)^{n-x}$ para $x \in \{0, 1, \dots, n\}$

Propiedades: $\mathbb{E}[X] = n\theta$, $\text{Var}(X) = n\theta(1 - \theta)$

3.5.3. Distribución Poisson

Definición 3.10 (Distribución Poisson). $X \sim \text{Poisson}(\lambda)$ modela eventos raros que ocurren a tasa λ .

FMP: $p(x) = \frac{e^{-\lambda} \lambda^x}{x!}$ para $x \in \{0, 1, 2, \dots\}$

Propiedades: $\mathbb{E}[X] = \text{Var}(X) = \lambda$

3.5.4. Distribución Binomial Negativa

Definición 3.11 (Distribución Binomial Negativa). $X \sim \text{NegBin}(r, \theta)$ modela el número de fallas antes de lograr r éxitos.

FMP: $p(x) = \binom{x+r-1}{x} \theta^r (1 - \theta)^x$ para $x \in \{0, 1, 2, \dots\}$

Propiedades: $\mathbb{E}[X] = \frac{r(1-\theta)}{\theta}$, $\text{Var}(X) = \frac{r(1-\theta)}{\theta^2}$

3.6. Distribuciones Continuas Importantes

3.6.1. Distribución Beta

Definición 3.12 (Distribución Beta). $X \sim \text{Beta}(\alpha, \beta)$ con soporte en $[0, 1]$.

FDP: $f(x) = \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} x^{\alpha-1} (1-x)^{\beta-1}$

Propiedades: $\mathbb{E}[X] = \frac{\alpha}{\alpha+\beta}$, $\text{Var}(X) = \frac{\alpha\beta}{(\alpha+\beta)^2(\alpha+\beta+1)}$

Rol bayesiano: Priori conjugada natural para verosimilitudes Bernoulli/Binomial.

3.6.2. Distribución Gamma

Definición 3.13 (Distribución Gamma). $X \sim \Gamma(\alpha, \beta)$ con forma $\alpha > 0$ y tasa $\beta > 0$.

FDP: $f(x) = \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x}$ para $x > 0$

Propiedades: $\mathbb{E}[X] = \frac{\alpha}{\beta}$, $\text{Var}(X) = \frac{\alpha}{\beta^2}$

Rol bayesiano: Priori conjugada para verosimilitudes Poisson.

3.6.3. Distribución Normal

Definición 3.14 (Distribución Normal). $X \sim \text{Normal}(\mu, \sigma^2)$ con ubicación μ y escala σ .

FDP: $f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$

Propiedades: $\mathbb{E}[X] = \mu$, $\text{Var}(X) = \sigma^2$

3.6.4. Distribución Log-Normal

Definición 3.15 (Distribución Log-Normal). $X \sim \text{LogNormal}(\mu, \sigma^2)$ si $\log(X) \sim \text{Normal}(\mu, \sigma^2)$.

FDP: $f(x) = \frac{1}{x\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(\log x - \mu)^2}{2\sigma^2}\right)$ para $x > 0$

Propiedades: $\mathbb{E}[X] = \exp\left(\mu + \frac{\sigma^2}{2}\right)$, $\text{Var}(X) = \exp(2\mu + \sigma^2)(\exp(\sigma^2) - 1)$
falta expo

4. La Regla de Bayes: El Fundamento

4.1. Probabilidad Condicional

Definición 4.1 (Probabilidad Condicional). Para eventos A y B con $\mathbb{P}(B) > 0$:

$$\mathbb{P}(A | B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}$$

4.2. Teorema de Bayes

Teorema 4.1 (Regla de Bayes). Para eventos A y B con $\mathbb{P}(B) > 0$:

$$\mathbb{P}(A | B) = \frac{\mathbb{P}(B | A)\mathbb{P}(A)}{\mathbb{P}(B)}$$

Forma extendida: Si $\{B_1, B_2, \dots, B_k\}$ forma una partición de Ω :

$$\mathbb{P}(B_i | A) = \frac{\mathbb{P}(A | B_i)\mathbb{P}(B_i)}{\sum_{j=1}^k \mathbb{P}(A | B_j)\mathbb{P}(B_j)}$$

4.3. Inferencia Estadística Bayesiana

En contextos estadísticos, la regla de Bayes se convierte en:

$$\pi(\theta | x) = \frac{L(x | \theta)\pi(\theta)}{m(x)}$$

Donde:

- $\pi(\theta)$: **Distribución priori** (creencias antes de observar datos)
- $L(x | \theta)$: **Función de verosimilitud** (probabilidad de datos dado parámetro)
- $\pi(\theta | x)$: **Distribución posteriori** (creencias actualizadas tras observar datos)
- $m(x) = \int L(x | \theta)\pi(\theta) d\theta$: **Verosimilitud marginal** (constante normalizadora)

4.4. Proceso de Aprendizaje Bayesiano

1. **Especificación de priori:** Codificar creencias iniciales sobre θ
2. **Observación de datos:** Recopilar datos x
3. **Evaluación de verosimilitud:** Evaluar $\mathbb{P}(x | \theta)$ para diferentes valores de θ
4. **Cómputo de posteriori:** Aplicar regla de Bayes para actualizar creencias
5. **Decisión/Predicción:** Usar posteriori para inferencia

5. Intercambiabilidad

5.1. Definición e Intuición

Definición 5.1 (Intercambiabilidad). Las variables aleatorias X_1, X_2, \dots, X_n son intercambiables si su distribución conjunta es invariante bajo permutaciones:

$$\mathbb{P}(X_1 = x_1, \dots, X_n = x_n) = \mathbb{P}(X_{\pi(1)} = x_1, \dots, X_{\pi(n)} = x_n)$$

para cualquier permutación π .

Intuición: No podemos distinguir entre las variables basándose en sus índices—son “simétricas” en nuestras creencias.

5.2. Teorema de De Finetti

Teorema 5.1 (De Finetti). Si X_1, X_2, \dots son infinitamente intercambiables, entonces existe una medida aleatoria P tal que:

$$\mathbb{P}(X_1 \in A_1, \dots, X_n \in A_n) = \int \prod_{i=1}^n P(A_i) d\mu(P)$$

Esto justifica el enfoque bayesiano: las observaciones intercambiables pueden modelarse como condicionalmente independientes dado un parámetro desconocido.

5.3. Implicaciones Prácticas

1. **Justifica modelos paramétricos:** La intercambiabilidad lleva naturalmente a asumir que las observaciones son i.i.d. dados los parámetros
2. **Elicitación de prioris:** Ayuda a determinar distribuciones prioris apropiadas
3. **Verificación de modelos:** Las violaciones sugieren inadecuación del modelo

6. Resumen y Próximos Pasos

Esta clase estableció los fundamentos filosóficos y matemáticos de la inferencia bayesiana:

1. **Fundamento filosófico:** La estadística interpreta más que explicar; la incertidumbre es fundamental
2. **Marco matemático:** La teoría de probabilidad proporciona el lenguaje para la incertidumbre
3. **Regla de Bayes:** El mecanismo para actualizar creencias con nueva información
4. **Intercambiabilidad:** El principio que justifica los modelos bayesianos paramétricos

Temas de la próxima clase:

- Prioris conjugadas y cómputo de posteriori
- Pruebas de hipótesis bayesianas y selección de modelos
- Métodos computacionales (MCMC, inferencia variacional)
- Modelos jerárquicos y Bayes empírico

Referencias

- [1] Luis Rincón. *Una introducción a la estadística inferencial*. Universidad Nacional Autónoma de México, México, 2019.