

Inferencia Bayesiana

Una Herramienta para el Análisis de Datos

Notas del curso, UNAM Agosto-Diciembre 2025

Autor: Imelda Trejo

23 de septiembre de 2025

Resumen

Estas notas introducen los fundamentos de la inferencia bayesiana para estudiantes de maestría y doctorado en matemáticas del Centro de Ciencias Matemáticas, UNAM Morelia. Nos enfocamos en la aplicabilidad de ésta que en las bases matemáticas rigurosas.

Índice

1. Contexto Histórico	4
2. Introducción a la Estadística	5
2.1. ¿Qué es la estadística?	5
2.2. Una Distinción Fundamental: Interpretación vs. Explicación .	5
2.3. Por qué importa esta distinción	6
2.4. Incertidumbre en Estadística	6
2.4.1. Cuantificación de la Incertidumbre	7
2.5. El Paradigma Bayesiano	7
2.6. Introducción al análisis de datos	7
2.6.1. Conceptos fundamentales	7
2.6.2. Clasificación de variables	9
2.6.3. La función <code>class()</code> en R	11
2.7. Ejercicios de cómputo	12
3. Probabilidad y variables aleatorias	12
3.1. Axiomas de probabilidad (axiomas de Kolmogórov)	13
3.2. Particiones	13
3.3. Probabilidad condicional	14

3.4.	Regla de Bayes	14
3.5.	Variables aleatorias y densidades de probabilidad	17
3.6.	Definiciones de esperanza y varianza	18
3.7.	Distribuciones Discretas Importantes	18
3.7.1.	Distribución Bernoulli	18
3.7.2.	Distribución Binomial	19
3.7.3.	Distribución Poisson	19
3.7.4.	Distribución Binomial Negativa	19
3.8.	Distribuciones Continuas Importantes	20
3.8.1.	Distribución Beta	20
3.8.2.	Distribución Gamma	20
3.8.3.	Distribución Normal	20
3.8.4.	Distribución Log-Normal	21
3.9.	Distribuciones conjunta y marginal	21
3.10.	Distribución condicional	22
4.	Inferencia Estadística	23
4.1.	Estimación por Máxima Verosimilitud	23
5.	Inferencia Bayesiana	26
5.1.	Variables aleatorias independientes	26
5.2.	Intercambiabilidad	27
5.3.	Teorema de Finetti	27
5.4.	El paradigma Bayesiano	27
5.5.	Familia de distribuciones conjugadas	28
5.5.1.	Beta-Binomial	28
5.5.2.	Normal-Normal	28
5.5.3.	Poisson–Gamma	28
5.5.4.	Exponencial - Gamma	30
5.5.5.	Exponencial–y generalizaciones	30
5.6.	Distribución a priori no informativa	31
6.	Intervalos de Credibilidad Bayesiano	32
6.1.	Credible Interval (CrI)	32
6.2.	Quantile-based Credible Interval	32
6.3.	Highest Density Interval (HDI)	33
7.	El método de Monte Carlo	33
7.1.	Aproximación de la densidad Posterior	34
7.2.	Estimación de Cantidades de Interés	34

8. El Algoritmo de Metropolis-Hastings con Caminata Aleatoria en MCMC	35
8.1. ¿Por qué necesitamos MCMC?	36
8.2. Fundamentos: Cadenas de Markov	36
8.3. La Caminata Aleatoria: El Ejemplo Más Simple de Cadena de Markov	36
8.4. Visualización de la Caminata Aleatoria	37
8.5. Tipos de Propuestas para la Caminata Aleatoria	37
8.5.1. Propuesta Normal Multivariada (La Más Común)	37
8.6. Idea Central del Algoritmo	38
8.7. El Algoritmo de Metropolis-Hastings	38
8.8. ¿Por qué Funciona este Mecanismo?	39
8.9. Consideraciones Numéricas Importantes	39
8.9.1. Trabajar en Escala Logarítmica	39
8.10. Algoritmo Completo	39
8.11. Calibración y Diagnósticos	41
8.11.1. El Papel Crucial de Σ	41
8.11.2. Ajuste de la Matriz de Propuesta, Σ	41
8.11.3. Estrategia de Calibración	41
8.11.4. Diagnosticar la Convergencia	41
8.12. Otras recomendaciones: transformaciones de parámetros	42
9. Regresión Lineal Bayesiana y la Familia Exponencial	43

1. Contexto Histórico

El término de inferencia Bayesiana es en honor a Thomas Bayes.



Figura 1: Esta es probablemente la única imagen que se tiene de Thomas Bayes, imagen obtenida de https://en.wikipedia.org/wiki/Thomas_Bayes

Thomas Bayes (1701-1761) fue un matemático y estadístico inglés que formuló el **teorema de Bayes**, una regla fundamental en estadística y aprendizaje automático moderno. Su trabajo dio origen a toda un área de la estadística: la **estadística bayesiana**, que se centra en determinar la probabilidad de un evento basándose en el conocimiento previo de condiciones que puedan estar relacionadas con dicho evento. Esto es, para dos eventos A y B con, $\mathbb{P}(B) > 0$:

$$\mathbb{P}(A | B) = \frac{\mathbb{P}(B | A)\mathbb{P}(A)}{\mathbb{P}(B)}$$

Aquí, el evento A no lo conocemos con precisión, pero creemos que este evento tiene una distribución $\mathbb{P}(A)$, que también se le conoce como *distribución a priori*. Luego, la probabilidad de A se actualiza al conocer la relación entre los eventos A y B . Siendo, $\mathbb{P}(A | B)$ la *distribución posterior*, distribución que resulta al incorporar los nuevos conocimientos sobre el evento A .

En nuestro contexto estimaremos el parámetro θ dado datos:

$$\mathbb{P}(\theta | \text{Datos}) = \frac{\mathbb{P}(\text{Datos} | \theta)\pi(\theta)}{\mathbb{P}(\text{Datos})}$$

El teorema de Bayes proporciona un marco matemático para actualizar nuestras creencias (falta de conocimientos) sobre cantidades inciertas a medida que observamos nuevos datos—un proceso que refleja cómo progresa el conocimiento científico.

2. Introducción a la Estadística

2.1. ¿Qué es la estadística?

La estadística es la ciencia que **recopila, organiza, analiza e interpreta datos** para entender fenómenos y ayudar en la toma de decisiones. Podemos dividirla en dos ramas principales:

- **Estadística descriptiva:** Resume y describe los datos mediante tablas, gráficas y medidas como media, mediana y varianza.
- **Estadística inferencial:** Utiliza datos muestrales para hacer inferencias sobre una población o proceso subyacente.

2.2. Una Distinción Fundamental: Interpretación vs. Explicación

“La estadística debe considerarse una interpretación de los fenómenos naturales, más que una explicación.”

Esta afirmación destaca un concepto crucial:

- La **estadística no explica por qué ocurre algo**; en cambio, **resume lo que observamos y cuantifica la incertidumbre** en nuestras observaciones. La forma de cuantificar la incertidumbre es con probabilidades.
- La **estadística** nos dice: *“Dadas estas observaciones, así es como se comportan los datos, y esta es la probabilidad de que este patrón sea real.”*
- La **explicación** (el “por qué”) típicamente proviene de una **teoría científica o modelo causal**.

Ejemplo 2.1. Patrones de influenza estacional.

- **Fenómeno:** “Los casos de gripe aumentan durante el invierno.”

- **Análisis estadístico:** Analiza datos históricos, calcula aumentos promedio, estima probabilidades de brotes.
- **Explicación científica:** “El virus sobrevive mejor a temperaturas frías, y las personas pasan más tiempo en espacios cerrados en proximidad.”

2.3. Por qué importa esta distinción

Confundir interpretación estadística con explicación causal lleva a:

1. Creer que correlación implica causalidad
2. Aplicar incorrectamente resultados estadísticos fuera de su contexto científico
3. Ignorar que la estadística **depende de la calidad y representatividad de los datos**

Ejemplo 2.2 (Ejemplo clásico). Las ventas de helado y los incidentes de ahogamiento muestran correlación positiva.

- **Observación estadística:** Cuando aumentan las ventas de helado, también aumentan los ahogamientos.
- **Inferencia causal incorrecta:** El helado causa ahogamientos.
- **Explicación real:** El calor es la causa común—en verano, más gente compra helado y más gente va a nadar, resultando en más ahogamientos.

2.4. Incertidumbre en Estadística

La **incertidumbre** representa **lo que no sabemos con certeza** sobre un fenómeno o valor de parámetro. En modelado matemático y análisis de datos, la incertidumbre surge de:

1. **Errores de medición** en la recolección de datos
2. **Variabilidad natural** en los fenómenos
3. **Observaciones limitadas**—observamos muestras, no poblaciones completas
4. **Limitaciones muestrales**—muestras pequeñas o no representativas

5. Inadecuación del modelo—los modelos son simplificaciones de la realidad

Ruido en los datos es otra expresión usada para expresar incertidumbre en las mediciones de los datos.

2.4.1. Cuantificación de la Incertidumbre

La estadística **cuantifica** esta incertidumbre mediante diferentes enfoques:

- **Enfoque frecuentista:** Intervalos de confianza, valores p
- **Enfoque bayesiano:** Distribuciones posteriores, intervalos creíbles

2.5. El Paradigma Bayesiano

Principio bayesiano fundamental: Cualquier cantidad que no conocemos con certeza (ya sea un parámetro, resultado futuro, o proceso no observado) se representa mediante una **distribución de probabilidad**.

Esta representación probabilística nos permite:

- Expresar grados de conocimiento sobre cantidades desconocidas
- Actualizar estos conocimientos conforme nuevos datos se vuelven disponibles
- Hacer predicciones con incertidumbre cuantificada

Usando la distribución de probabilidad es fácil calcular predicciones con intervalos de credibilidad, ver Figura 2.

2.6. Introducción al análisis de datos

Tarea: Leer el capítulo 1 del libro [5]

A continuación se presenta un resumen del capítulo.

2.6.1. Conceptos fundamentales

El análisis de datos es una disciplina que nos permite extraer información significativa de conjuntos de observaciones. Para comprender esta disciplina, es esencial dominar algunos conceptos básicos que forman la base de todo estudio estadístico.




Figura 2: Distribución Normal estándar: $\mu = 0$, $\sigma = 1$.

Definiciones básicas

Definición 2.1 (Población). Una población es un conjunto de personas, objetos o eventos, de los cuales nos interesa estudiar algunas de sus características.

Definición 2.2 (Muestra). Una muestra es cualquier subconjunto de una población.

Definición 2.3 (Variable). Una variable es una característica de interés que posee cada elemento de una población y que podemos medir o registrar.

Una variable también puede considerarse como una pregunta que se le hace a cada elemento de la población, produciendo una respuesta en cada caso.

Ejemplo: En una población humana, podemos considerar la variable o pregunta: “¿Eres estudiante?” y obtener como respuesta “sí” o “no”.

Definición 2.4 (Datos). Mediante el término datos se entiende al conjunto de observaciones de una o varias variables de interés para todos los elementos de una muestra.

Generalmente, un conjunto de datos se organiza y almacena en una computadora en la forma de un arreglo bidimensional o tabla, donde las filas representan las observaciones (elementos de la muestra) y las columnas representan las variables.

Ejemplo de organización de datos Consideremos un estudio sobre estudiantes universitarios. La siguiente tabla muestra cómo se organizarían los datos:

ID	Edad	Sexo	Carrera	Promedio
1	20	Masculino	Ingeniería	8.5
2	19	Femenino	Medicina	9.2
3	21	Masculino	Derecho	7.8
4	22	Femenino	Psicología	8.9
5	20	Femenino	Ingeniería	8.1

Tabla 1: Ejemplo de organización de datos en forma tabular

2.6.2. Clasificación de variables

En el análisis de datos, es fundamental entender el tipo de variable con la que se trabaja, ya que esto determina qué métodos estadísticos son adecuados para su análisis. Las variables se clasifican principalmente en dos grandes categorías: cuantitativas y cualitativas.

Variables cuantitativas

Definición 1.5 (Variable cuantitativa): Una variable es cuantitativa si sus valores son números y representan una cantidad.

Las variables cuantitativas se subdividen en:

- **Discretas:** Toman valores enteros o contables. Ejemplos: número de hijos en una familia, número de automóviles vendidos, cantidad de libros en una biblioteca.
- **Continuas:** Pueden tomar cualquier valor dentro de un intervalo. Ejemplos: estatura, peso, longitud de un tornillo, temperatura.

Características de las variables cuantitativas:

- Permiten calcular promedios, varianzas y otras medidas estadísticas.
- Se pueden aplicar técnicas estadísticas (estimación de parámetros usando Poisson) paramétricas.
- Tienen sentido las operaciones aritméticas (suma, resta, multiplicación, división).
- Poseen un orden natural y distancias medibles entre valores.

Variables cualitativas (categóricas)

Definición 2.5 (Variable cualitativa). Una variable es cualitativa si sus valores representan una cualidad, un atributo o una categoría. Se les llama también variables categóricas.

Las variables cualitativas se caracterizan por:

- Tomar valores en un conjunto limitado de categorías.
- Pueden o no tener un orden natural.
- Se utilizan para clasificar observaciones en grupos.

Las variables cualitativas se subdividen en:

- **Nominales:** No tienen un orden natural entre sus categorías.
- **Ordinales:** Sus categorías tienen un orden natural o jerárquico.
- **Binarias o dicotómicas:** Caso especial que toma exactamente dos valores.

Ejemplos de variables cualitativas:

- **Nominales:**
 - Grupo sanguíneo: A, B, AB, O
 - Estado civil: soltero, casado, divorciado, viudo
 - Color de ojos: azul, marrón, verde
 - Nacionalidad: mexicana, estadounidense, canadiense
- **Ordinales:**
 - Nivel educativo: primaria, secundaria, preparatoria, universidad
 - Calificación: excelente, bueno, regular, malo
 - Grupos de edad: joven, adulto, mayor
- **Binarias o dicotómicas:**
 - Sexo: masculino o femenino
 - Respuesta: sí o no
 - Presencia de enfermedad: presente o ausente
 - Estado de empleo: empleado o desempleado

Importancia de la clasificación

La correcta identificación del tipo de variable es crucial porque:

- Determina qué pruebas y medidas pueden aplicarse.
 - Variables numéricas: pruebas paramétricas, correlaciones, regresión, etc.
 - Variables categóricas: pruebas de proporciones, chi-cuadrada, etc.
- Define el tipo de representación gráfica.
 - Categóricas: diagramas de barras, diagramas de pastel.
 - Numéricas: histogramas, diagramas de caja (*boxplots*), funciones de densidad.
- **Interpretación de resultados:** Una media tiene sentido para variables numéricas, pero no para categóricas nominales.
- **Selección de medidas de tendencia central y dispersión:**
 - Numéricas: media, mediana, moda, desviación estándar, varianza, percentiles, cuartiles.
 - Categóricas: moda, frecuencias absolutas y relativas, porcentajes.

$$\text{Frecuencia absoluta} = \frac{\text{número de observaciones favorables}}{\text{Total de observaciones}}$$

2.6.3. La función `class()` en R

Devuelve el **tipo de dato** que R asigna a un objeto, indicando cómo R interpreta la variable y qué operaciones son posibles.

Tabla 2: Tipos de datos más comunes en R según `class()`

Tipo de dato	Descripción	Ejemplo
<code>numeric</code>	Números reales (decimales)	3.14
<code>integer</code>	Números enteros	42L
<code>character</code>	Texto	"Hola"
<code>logical</code>	Valores verdadero/falso	TRUE
<code>factor</code>	Variable categórica con niveles	<code>factor(c('A','B'))</code>
<code>Date</code>	Fechas	<code>as.Date("2025-08-12")</code>

2.7. Ejercicios de cómputo

Las bases de datos se encuentran en

https://github.com/imelit/Bayesian_inference_class_2025/tree/main

Actividades:

- ¿Qué tipo de variables son edad, sexo?
- ¿Cuántos tipos de enfermedades ajenas a las respiratorias se reportan (comorbidades)? Hacer una gráfica de barras con sus respectivas frecuencias.
- ¿Cuántos tipos de enfermedades respiratorias se reportaron? Realiza una gráfica de barras con sus respectivas frecuencias.
- Cuántos tipos de influenza se reportaron? Realiza una gráfica de barras para comparar estas.
- De entre los casos reportados por influenza. Realiza una gráfica de barras del total de casos estratificado por meses, partiendo de octubre a mayo, tempora de influenza, <https://www.cdc.gov/flu/about/season.html>.
- Visualiza la serie de tiempo de Influenza estratificado por grupos de edad (casos contra tiempo).
- ¿Qué relación hay entre comorbidades e infectados por influenza (que pasa con los decesos)?

Guia para el análisis:

<https://www.cdc.gov/fluview/overview/fluview-interactive.html>

3. Probabilidad y variables aleatorias

La probabilidad es el lenguaje y marco matemático que usamos para formular la inferencia estadística. Con la probabilidad, la inferencia estadística nos permite hacer afirmaciones o predicciones sobre una población más allá de los datos observados en una muestra¹

¹Para esta sección voy a usar el libro de clase [4], capítulo 2, y [3], capítulos 1 y 2.

3.1. Axiomas de probabilidad (axiomas de Kolmogórov)

Consideremos un experimento cuya espacio muestral es Ω . Para cada evento E del espacio muestral, suponga que el número $\mathbb{P}(E)$ es definido y satisface los siguientes axiomas.

Axioma 1

$$0 \leq \mathbb{P}(E) \leq 1$$

Axioma 2

$$\mathbb{P}(\Omega) = 1$$

Axioma 3 Para cualquier secuencia de eventos mutuamente exclusivos $E_1, E_2, \dots$ (esto es para cualquier $E_i \cap E_j = \emptyset$ con $i \neq j$),

$$\mathbb{P}\left(\bigcup_{i=1}^{\infty} E_i\right) = \sum_{i=1}^{\infty} \mathbb{P}(E_i)$$

Observación 3.1. Establecimos que $\mathbb{P}(E)$ está bien definida; esto es

$$\mathbb{P} : \Omega \rightarrow [0, 1]$$

una función que asigna a cada evento E un número real entre 0 y 1. De manera formal, esto tiene sentido en el contexto de espacios medibles, ver por ejemplo [1]. Sin embargo, en estas notas no entraremos en esos detalles.

Nos enfocaremos en los casos prácticos, donde casi todos los eventos con los que trabajamos son medibles. También supondremos que las variables aleatorias están bien definidas y no tendremos problemas “patológicos” de teoría de la medida, ver también la definición formal de variable aleatoria en [1].

3.2. Particiones

Pag. 14-16 del libro [4]

Definición 3.1 (Partición). Una colección de eventos $\{H_1, H_2, \dots, H_k\}$ forma una partición de H si:

1. $H_i \cap H_j = \emptyset$ para $i \neq j$ (mutuamente excluyentes)
2. $\bigcup_{i=1}^k H_i = H$ (exhaustivos)
3. $\mathbb{P}(H_i) > 0$ para todo i

Aquí $H = \Omega$ es el espacio muestral u conjunto de hipótesis a estudiar.

Ejemplos (libro pag 15):

Let H be someone's religious orientation. Partitions include

- {Protestant, Catholic, Jewish, other, none};
- {Christian, non-Christian};
- {atheist, monotheist, multitheist}.

Let H be someone's number of children. Partitions include

- {0, 1, 2, 3 or more};
- {0, 1, 2, 3, 4, 5, 6, ...}.

Let H be the relationship between smoking and hypertension in a given population. Partitions include

- {some relationship, no relationship};
- {negative correlation, zero correlation, positive correlation}.

3.3. Probabilidad condicional

Definición 3.2. Sean E y F dos eventos, si $\mathbb{P}(F) \geq 0$, se define

$$\mathbb{P}(E|F) := \frac{\mathbb{P}(E \cap F)}{\mathbb{P}(F)},$$

y se lee, la probabilidad condicional de que ocurra E dado que F ya ocurrió.

3.4. Regla de Bayes

Supongamos que $\{H_1, H_2, \dots, H_K\}$ es una partición de eventos del espacio muestral H , E es un evento de H y $\mathbb{P}$ es una función de probabilidad definida para todos los eventos de H . Los axiomas de probabilidad implican las siguientes identidades.

Regla de la probabilidad total (marginal)

$$\Pr(E) = \sum_{k=1}^K \Pr(E \cap H_k) = \sum_{k=1}^K \Pr(E | H_k) \Pr(H_k)$$

Regla de Bayes (forma extendida):

$$\mathbb{P}(H_j | E) = \frac{\mathbb{P}(E | H_j)\mathbb{P}(H_j)}{\mathbb{P}(E)} = \frac{\mathbb{P}(E | H_j)\mathbb{P}(H_j)}{\sum_{k=1}^K \mathbb{P}(E | H_k)\mathbb{P}(H_k)}$$

La **regla de la probabilidad total** es una herramienta muy útil de la probabilidad, ya que nos permite calcular la probabilidad de un evento E en situaciones donde su cálculo directo es complicado o imposible.

Ejemplo: Regla de la probabilidad total

Supongamos que una fábrica recibe piezas de tres proveedores distintos. Cada proveedor abastece un porcentaje diferente de la producción total, y además tiene distinta calidad en sus envíos. Queremos calcular la probabilidad total de que una pieza seleccionada al azar resulte defectuosa (esto es el evento E).

Los escenarios (hipótesis) son:

- H_1 : Proveedor 1 envía el 40 % de las piezas,
- H_2 : Proveedor 2 envía el 35 %,
- H_3 : Proveedor 3 envía el 25 %.

También se conocen las probabilidades de defecto condicionadas al proveedor:

$$\mathbb{P}(E | H_1) = 0.01, \quad \mathbb{P}(E | H_2) = 0.03, \quad \mathbb{P}(E | H_3) = 0.02.$$

Directamente calcular $\mathbb{P}(E)$ es complicado porque intervienen varios proveedores. Aquí es donde la **ley de la probabilidad total** es esencial: descomponemos el cálculo en función de los escenarios H_i .

$$\mathbb{P}(E) = \mathbb{P}(E | H_1)\mathbb{P}(H_1) + \mathbb{P}(E | H_2)\mathbb{P}(H_2) + \mathbb{P}(E | H_3)\mathbb{P}(H_3).$$

$$\mathbb{P}(E) = (0.01)(0.40) + (0.03)(0.35) + (0.02)(0.25).$$

$$\mathbb{P}(E) = 0.0195.$$

Conclusión: La probabilidad de que una pieza elegida al azar sea defectuosa es de 1.95 %.

En inferencia bayesiana, el conjunto

$$\{H_1, H_2, \dots, H_K\}$$

suele referirse a **hipótesis mutuamente excluyentes** o a **escenarios de la naturaleza**. El evento E representa la **evidencia observada**, es decir, el resultado de un experimento, encuesta o estudio.

Cuando queremos **comparar hipótesis después de observar los datos**, una herramienta útil es el **cociente de probabilidades a posteriori**:

$$\frac{\mathbb{P}(H_i | E)}{\mathbb{P}(H_j | E)}.$$

Aplicando la **regla de Bayes**, se obtiene:

$$\frac{\mathbb{P}(H_i | E)}{\mathbb{P}(H_j | E)} = \frac{\mathbb{P}(E | H_i)\mathbb{P}(H_i)}{\mathbb{P}(E | H_j)\mathbb{P}(H_j)}.$$

Esta expresión se puede reorganizar como:

$$\frac{\mathbb{P}(H_i | E)}{\mathbb{P}(H_j | E)} = \underbrace{\frac{\mathbb{P}(E | H_i)}{\mathbb{P}(E | H_j)}}_{\text{Factor de Bayes}} \times \underbrace{\frac{\mathbb{P}(H_i)}{\mathbb{P}(H_j)}}_{\text{Creencias a priori}}.$$

Interpretación

- El **factor de Bayes** $\frac{\mathbb{P}(E|H_i)}{\mathbb{P}(E|H_j)}$ mide qué tan bien explica cada hipótesis la evidencia observada.
- El cociente $\frac{\mathbb{P}(H_i)}{\mathbb{P}(H_j)}$ refleja nuestras **creencias iniciales (a priori)**.
- En conjunto, el cociente a posteriori nos dice cómo deben ajustarse nuestras creencias una vez observada la evidencia.

Nota: la regla de Bayes no nos dice qué debemos creer después de ver los datos, sino cómo deben cambiar nuestras creencias previas al incorporar la información observada.

Ejemplo

Supongamos que queremos estimar el **nivel de apoyo a un candidato político**.

- Sea

$H = \{\text{todas los porcentajes posibles de apoyo al candidato A}\}.$

- Definimos dos hipótesis:

$H_1 = \{\text{más de la mitad de los votantes apoyan al candidato A}\},$

$H_2 = \{\text{menos o igual a la mitad de los votantes apoyan al candidato A}\}.$

- Definimos la evidencia:

$E = \{\text{en una encuesta, 54 de 100 personas dijeron apoyar al candidato A}\}.$

El conjunto $\{H_1, H_2\}$ forma una **partición** de H . De interés está calcular:

$$\mathbb{P}(H_1 | E), \quad \text{o bien} \quad \frac{\mathbb{P}(H_1 | E)}{\mathbb{P}(H_2 | E)}.$$

Resolvermos este ejemplo más adelante.

3.5. Variables aleatorias y densidades de probabilidad

Definición 3.3 (Variable Aleatoria). Una variable aleatoria X es una función medible $X : \Omega \rightarrow \mathbb{R}$.

Definición 3.4 (Variable aleatoria discreta). Una variable aleatoria X es *discreta* si toma valores en un conjunto contable. En este caso, la **función de masa de probabilidad** (fmp) se define como

$$p(x) = \mathbb{P}(X = x), \quad \text{donde} \quad \sum_x p(x) = 1.$$

Definición 3.5 (Variable aleatoria continua). Una variable aleatoria X es *continua* si existe una función $f(x) \geq 0$ tal que

$$\mathbb{P}(a < X \leq b) = \int_a^b f(x) dx \quad \text{para todo } a < b,$$

y además

$$\int_{-\infty}^{\infty} f(x) dx = 1.$$

A la función $f(x)$ se le llama **función de densidad de probabilidad** (fdp).

Observación 3.2 (Unificación de notación). En estas notas, por simplicidad, usaremos la misma letra $f(x)$ para referirnos tanto a la función de masa de probabilidad (en el caso discreto) como a la función de densidad de probabilidad (en el caso continuo). La diferencia estará dada por el contexto:

$$\mathbb{P}(X \in A) = \begin{cases} \sum_{x \in A} f(x), & \text{si } X \text{ es discreta,} \\ \int_A f(x) dx, & \text{si } X \text{ es continua.} \end{cases}$$

3.6. Definiciones de esperanza y varianza

Definición 3.6 (Esperanza o media). Sea X una variable aleatoria (discreta o continua) con función de densidad $f(x)$. La **esperanza** o **media** de X se define como

$$\mathbb{E}[X] = \mu = \begin{cases} \sum_x x f(x), & \text{si } X \text{ es discreta,} \\ \int_{-\infty}^{\infty} x f(x) dx, & \text{si } X \text{ es continua.} \end{cases}$$

Definición 3.7 (Varianza). La **varianza** de una variable aleatoria X es un número que mide la dispersión de los valores de X alrededor de su media $\mu = \mathbb{E}[X]$. Se define como

$$\text{Var}(X) = \mathbb{E}[(X - \mu)^2].$$

En forma explícita:

$$\text{Var}(X) = \begin{cases} \sum (x - \mu)^2 f(x), & \text{si } X \text{ es discreta,} \\ \int_{-\infty}^{\infty} (x - \mu)^2 f(x) dx, & \text{si } X \text{ es continua.} \end{cases}$$

Observación 3.3. Una fórmula equivalente y muy útil para la varianza es

$$\text{Var}(X) = \mathbb{E}[X^2] - (\mathbb{E}[X])^2.$$

3.7. Distribuciones Discretas Importantes

3.7.1. Distribución Bernoulli

Definición 3.8 (Distribución Bernoulli).

$$X \sim \text{Bernoulli}(\theta)$$

si $X = 0$ ó $X = 1$ con probabilidad de éxito $\mathbb{P}(X = 1) = \theta$.

fdp:

$$f(x) = \theta^x (1 - \theta)^{1-x}$$

para $x \in \{0, 1\}$

Propiedades: $\mathbb{E}[X] = \theta$, $\text{Var}(X) = \theta(1 - \theta)$

3.7.2. Distribución Binomial

Definición 3.9 (Distribución Binomial).

$$X \sim \text{Binomial}(n, \theta)$$

representa el número de éxitos en n ensayos independientes Bernoulli(θ).

fdp:

$$f(x) = \binom{n}{x} \theta^x (1 - \theta)^{n-x}$$

para $x \in \{0, 1, \dots, n\}$

Propiedades: $\mathbb{E}[X] = n\theta$, $\text{Var}(X) = n\theta(1 - \theta)$

3.7.3. Distribución Poisson

Definición 3.10 (Distribución Poisson).

$$X \sim \text{Poisson}(\lambda)$$

modela eventos que ocurren a tasa $\lambda > 0$.

FMP:

$$f(x) = \frac{e^{-\lambda} \lambda^x}{x!}$$

para $x \in \{0, 1, 2, \dots\}$

Propiedades: $\mathbb{E}[X] = \text{Var}(X) = \lambda$

3.7.4. Distribución Binomial Negativa

Definición 3.11 (Distribución Binomial Negativa).

$$X \sim \text{NegBin}(r, \theta)$$

modela el número de fallas antes de lograr r éxitos.

fdp:

$$f(x) = \binom{x+r-1}{x} \theta^r (1-\theta)^x$$

para $x \in \{0, 1, 2, \dots\}$

Propiedades: $\mathbb{E}[X] = \frac{r(1-\theta)}{\theta}$, $\text{Var}(X) = \frac{r(1-\theta)}{\theta^2} = E[X] \frac{1}{\theta}$.

3.8. Distribuciones Continuas Importantes

3.8.1. Distribución Beta

Definición 3.12 (Distribución Beta).

$$X \sim \text{Beta}(\alpha, \beta)$$

con soporte en $[0, 1]$.

FDP:

$$f(x) = \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} x^{\alpha-1} (1-x)^{\beta-1}, \quad 0 \leq x \leq 1$$

Propiedades: $\mathbb{E}[X] = \frac{\alpha}{\alpha+\beta}$, $\text{Var}(X) = \frac{\alpha\beta}{(\alpha+\beta)^2(\alpha+\beta+1)}$

3.8.2. Distribución Gamma

Definición 3.13 (Distribución Gamma).

$$X \sim \Gamma(\alpha, \beta)$$

con forma (shape) $\alpha > 0$ y tasa (rate) $\beta > 0$.

FDP: $f(x) = \frac{1}{\beta^\alpha \Gamma(\alpha)} x^{\alpha-1} e^{-\frac{x}{\beta}}$ para $x > 0$

Propiedades: $\mathbb{E}[X] = \frac{\alpha}{\beta}$, $\text{Var}(X) = \frac{\alpha}{\beta^2}$

3.8.3. Distribución Normal

Definición 3.14 (Distribución Normal).

$$X \sim \text{Normal}(\mu, \sigma^2)$$

con ubicación μ y escala σ .

FDP:

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$

Propiedades: $\mathbb{E}[X] = \mu$, $\text{Var}(X) = \sigma^2$

3.8.4. Distribución Log-Normal

Definición 3.15 (Distribución Log-Normal).

$$X \sim \text{LogNormal}(\mu, \sigma^2)$$

si

$$\log(X) \sim \text{Normal}(\mu, \sigma^2)$$

.

FDP: $f(x) = \frac{1}{x\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(\log x - \mu)^2}{2\sigma^2}\right)$ para $x > 0$

Propiedades: $\mathbb{E}[X] = \exp\left(\mu + \frac{\sigma^2}{2}\right)$, $\text{Var}(X) = \exp(2\mu + \sigma^2)(\exp(\sigma^2) - 1)$

distribución uniforme

distribución exponencial

3.9. Distribuciones conjunta y marginal

Definición 3.16 (Distribución conjunta). Sean X y Y dos variables aleatorias (discretas o continuas). La **distribución conjunta** de (X, Y) se describe mediante una función $f(x, y)$ tal que:

$$\mathbb{P}((X, Y) \in A) = \begin{cases} \sum_{(x,y) \in A} f(x, y), & \text{si } (X, Y) \text{ son discretas,} \\ \iint_A f(x, y) dx dy, & \text{si } (X, Y) \text{ son continuas.} \end{cases}$$

En ambos casos, se cumple que

$$f(x, y) \geq 0, \quad \sum_{x,y} f(x, y) = 1 \quad \text{o} \quad \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f(x, y) dx dy = 1.$$

Definición 3.17 (Distribuciones marginales). Las **distribuciones marginales** de X y Y se obtienen a partir de la distribución conjunta $f(x, y)$:

$$f_X(x) = \begin{cases} \sum_y f(x, y), & \text{si } (X, Y) \text{ son discretas,} \\ \int_{-\infty}^{\infty} f(x, y) dy, & \text{si } (X, Y) \text{ son continuas,} \end{cases}$$

$$f_Y(y) = \begin{cases} \sum_x f(x, y), & \text{si } (X, Y) \text{ son discretas,} \\ \int_{-\infty}^{\infty} f(x, y) dx, & \text{si } (X, Y) \text{ son continuas.} \end{cases}$$

De este modo, $f_X(x)$ y $f_Y(y)$ describen las probabilidades o densidades de X y Y por separado.

3.10. Distribución condicional

Definición 3.18 (Distribución condicional). Sean X y Y dos variables aleatorias con distribución conjunta $f(x, y)$ y marginales $f_X(x)$ y $f_Y(y)$.

La **distribución condicional** de X dado $Y = y$ se define como

$$f_{X|Y}(x | y) = \frac{f(x, y)}{f_Y(y)}, \quad \text{siempre que } f_Y(y) > 0.$$

De manera análoga, la distribución condicional de Y dado $X = x$ es

$$f_{Y|X}(y | x) = \frac{f(x, y)}{f_X(x)}, \quad \text{siempre que } f_X(x) > 0.$$

Observación 3.4. En notación unificada:

$$\mathbb{P}(X \in A | Y = y) = \begin{cases} \sum_{x \in A} f_{X|Y}(x | y), & \text{si } (X, Y) \text{ son discretas,} \\ \int_A f_{X|Y}(x | y) dx, & \text{si } (X, Y) \text{ son continuas.} \end{cases}$$

Observación 3.5 (Relación con la probabilidad condicional). La definición anterior generaliza la probabilidad condicional usual:

$$\mathbb{P}(X \in A | Y \in B) = \frac{\mathbb{P}((X, Y) \in A \times B)}{\mathbb{P}(Y \in B)},$$

siempre que $\mathbb{P}(Y \in B) > 0$.

De forma análoga, estas definiciones se extienden naturalmente al caso de la distribución conjunta de un número arbitrario de variables aleatorias

4. Inferencia Estadística

Dada una muestra aleatoria $\{Y_1, Y_2, \dots, Y_n\}$ de la variable Y , que supondremos

$$Y \sim f(y \mid \theta)$$

nuestro objetivo es usar la inferencia estadística para *obtener estimaciones* del parámetro desconocido θ que caracteriza la distribución de Y .

Nuestro primer acercamiento es usar estimadores puntuales calculados de la función de verosimilitud que a continuación se expondrá. Para esta sección, sigo el libro [3], capítulo 2. Sugiero leer ambos capítulos 1 y 2 para aprender los conceptos de función de decisión y riesgo; y profundizar en el tema de estimador puntual de máxima verosimilitud. Otra referencia es [2] donde se profundiza el estudio de estimadores usando la función de máxima verosimilitud.

4.1. Estimación por Máxima Verosimilitud

Supongamos que contamos con una función de densidad (o masa) de probabilidad

$$f(y \mid \theta),$$

y un conjunto de datos

$$Y_1 = y_1, Y_2 = y_2, \dots, Y_n = y_n$$

para la variable aleatoria Y .

Definición 4.1 (The likelihood function). Definimos la **función de verosimilitud** como

$$L(\theta) = \prod_{i=1}^n f(y_i \mid \theta).$$

Esta función depende solo de θ , ya que los valores y_i son observaciones fijas.

Definición 4.2 (Estimador de máxima verosimilitud). El valor θ que maximiza $L(\theta)$:

$$\hat{\theta}_{\text{MLE}} = \arg \max_{\theta \in \Theta} L(\theta)$$

se denomina **estimador de máxima verosimilitud** de θ .

Esta elección de θ por ser el máximo hace que los datos observados sean más plausibles bajo el modelo.

Ejemplo 1: estimar la probabilidad de éxito de una Distribución Bernoulli

Supongamos $Y_1, \dots, Y_n \sim \text{Bernoulli}(\theta)$, con $\theta \in (0, 1)$.

- La verosimilitud es

$$\begin{aligned} L(\theta) &= \prod_{i=1}^n \theta^{y_i} (1 - \theta)^{1-y_i} \\ &= \theta^{\sum_{i=1}^n y_i} (1 - \theta)^{\sum_{i=1}^n (1-y_i)}. \end{aligned}$$

- La log-verosimilitud es

$$\ell(\theta) = \sum_{i=1}^n [y_i \log \theta + (1 - y_i) \log(1 - \theta)].$$

- Derivando e igualando a cero:

$$\frac{d}{d\theta} \ell(\theta) = \frac{\sum_{i=1}^n y_i}{\theta} - \frac{n - \sum_{i=1}^n y_i}{1 - \theta} = 0.$$

- Resolviendo se obtiene el MLE:

$$\hat{\theta}_{\text{MLE}} = \frac{1}{n} \sum_{i=1}^n y_i,$$

es decir, la proporción muestral de éxitos (frecuentista).

Ejemplo 2: Estimar la media de una Distribución Normal

Suponga que $Y_1, \dots, Y_n$ es una muestra aleatoria con

$$Y_i \sim \mathcal{N}(\mu, \sigma^2),$$

donde μ y σ^2 son los parámetros poblacionales a estimar.

Función de verosimilitud (en términos de θ).

Primero denotemos con $\theta_1 = \mu$ y $\theta_2 = \sigma^2$, el espacio de parámetros es $\Theta = (-\infty, \infty) \times (0, \infty)$. Buscamos (θ_1, θ_2) tal que maximice la función:

$$\begin{aligned} L(\mu, \sigma^2 \mid y_{1:n}) &= \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left\{-\frac{1}{2\sigma^2}(y_i - \mu)^2\right\} \\ &= (2\pi\sigma^2)^{-n/2} \exp\left\{-\frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \mu)^2\right\}. \end{aligned}$$

Log-verosimilitud:

$$\ell(\theta \mid y_{1:n}) = \log L(\mu, \sigma^2 \mid y_{1:n}) = -\frac{n}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \mu)^2.$$

$$\ell(\theta \mid y_{1:n}) = \log L(\theta \mid y_{1:n}) = -\frac{n}{2} \log(2\pi\theta_2) - \frac{1}{2\theta_2} \sum_{i=1}^n (y_i - \theta_1)^2.$$

Gradiente de la log-verosimilitud:

$$\frac{\partial \ell(\theta_1, \theta_2 \mid y_{1:n})}{\partial \theta_1} = \frac{1}{\theta_2} \left(\sum_{i=1}^n y_i - n\theta_1 \right).$$

$$\frac{\partial \ell(\theta_1, \theta_2 \mid y_{1:n})}{\partial \theta_2} = -\frac{n}{2} \frac{1}{\theta_2} + \frac{1}{2\theta_2^2} \sum_{i=1}^n (y_i - \theta_1)^2.$$

Igualando a cero simultáneamente:

$$\frac{\partial \ell(\theta \mid y_{1:n})}{\partial \theta_1} = 0 \implies \sum_{i=1}^n y_i - n\theta = 0 \implies \hat{\theta} = \frac{1}{n} \sum_{i=1}^n y_i = \bar{Y}.$$

y

$$\frac{\partial \ell(\theta \mid y_{1:n})}{\partial \theta_2} = 0 \implies \theta_2 = \frac{1}{n} \sum_{i=1}^n (y_i - \theta_1).$$

Por lo tanto,

$$\begin{aligned} \hat{\theta}_1 &= \bar{Y} \\ \hat{\theta}_2 &= \frac{1}{n} \sum_{i=1}^n (y_i - \bar{Y}). \end{aligned}$$

Tarea: muestra que $\hat{\theta}$ es un máximo global de la función de verosimilitud.

Observación 4.1 (Sobre la existencia y unicidad del MLE). La unicidad del estimador de máxima verosimilitud (MLE) no está garantizada, y en ciertos casos pueden existir al menos dos valores de parámetro $\hat{\theta}_1 \neq \hat{\theta}_2$ tales que

$$L(\hat{\theta}_1) = L(\hat{\theta}_2) = \arg \max_{\theta \in \Theta} L(\theta).$$

En otras situaciones, el MLE puede no existir en absoluto en todo el espacio paramétrico Θ , Ver ejmplos del Capítulo 2 del libro [2]

Laboratorios: visualizar el espacio de parámetros y las curvas de nivel que genera la función de verosimilitud.

Observación 4.2 (Interpretación y propiedades del MLE).

■ **Enfoque frecuentista:**

El MLE trata los datos y_i como observaciones fijas y considera θ como un parámetro puntual fijo desconocido.

■ **Objetivo del MLE:** Busca el valor de θ que hace que los datos observados sean más plausibles, proporcionando así una estimación puntual del parámetro.

■ **Propiedades deseables:** Bajo condiciones generales y para muestras grandes, el MLE tiene tres características importantes:

- *Consistencia:* A medida que aumenta el tamaño de la muestra, el estimador $\hat{\theta}_{\text{MLE}}$ se aproxima al valor verdadero θ .
- *Eficiencia:* Entre estimadores insesgados, el MLE tiende a tener la menor varianza posible, es decir, produce estimaciones más precisas.
- *Normalidad asintótica:* Para muestras grandes, la distribución de $\hat{\theta}_{\text{MLE}}$ se aproxima a una distribución Normal centrada en θ , lo que permite construir intervalos de confianza y realizar pruebas de hipótesis.

Observación 4.3. En la práctica, supondremos que los datos han sido generados por una función de distribución, que consideramos como el *modelo* que describe los datos. La elección del modelo suele basarse en la experiencia y el conocimiento previo sobre la naturaleza de los datos: su forma, rango de valores y contexto en el que fueron observados.

5. Inferencia Bayesiana

Para esta sección nuevamente usamos el libro de clase [4], a partir de la página 26, Capítulo 2.

5.1. Variables aleatorias independientes

ver libro

5.2. Intercambiabilidad

ver libro

5.3. Teorema de Finetti

ver libro.

5.4. El paradigma Bayesiano

Combinando todos los conceptos y teorema antes, tenemos lo siguiente.

Para un conjunto de datos $\{Y_1 = y_1, \dots, Y_n = y_n\}$ que son condicionalmente independientes e idénticamente distribuidos (i.i.d) dado el parámetro θ :

$$\mathbb{P}(y_1, y_2, \dots, y_n \mid \theta) = L(\theta) = \prod_{i=1}^n f(y_i \mid \theta).$$

con $f(y_i, \theta)$ la función de distribución de Y_i , $i = 1, \dots, n$. Por el teorema de Finetti:

$$\mathbb{P}(y_1, y_2, \dots, y_n) = \int L(\theta)\pi(\theta)d\theta.$$

Por lo tanto, la regla de Bayes se convierte en:

$$\mathbb{P}(\theta \mid y_1, \dots, y_n) = \frac{L(\theta)\pi(\theta)}{m(y)} \quad (1)$$

Donde:

- $\pi(\theta)$: **Distribución priori** (creencias o conocimiento antes de observar datos)
- $L(y \mid \theta)$: **Función de verosimilitud** (probabilidad de datos dado parámetro)
- $\mathbb{P}(\theta \mid y)$: **Distribución posteriori** (creencias actualizadas tras observar datos)
- $m(y) = \int L(y \mid \theta)\pi(\theta) d\theta$: **Verosimilitud marginal** (constante normalizadora)

Ejemplo 1: estimar la probabilidad de éxito de una Distribución Bernoulli

Ver libro de la página 31 a la 38. Los datos vienen de una encuesta donde a un grupo de mujeres mayores o iguales a 65 se les pregunta: ¿es generalmente feliz? En este caso $Y_i \in \{0, 1\}$, el resultado 1 corresponde a una respuesta sí que es un éxito. El objetivo es estimar θ la probabilidad de que resulte un éxito.

Conclusión. El parámetro θ sigue una distribución a priori $\pi(\theta)$ uniforme. Luego, la posteriori de θ resulta ser una distribución beta.

5.5. Familia de distribuciones conjugadas

Definición 5.1. Una clase de distribuciones a priori $\mathcal{P}$ para el parámetro θ se dice **conjugada** con respecto al modelo muestral de datos $\{L(y | \theta)\}$ si

$$\forall \pi(\theta) \in \mathcal{P} \implies \mathbb{P}(\theta | y_1, \dots, y_n) \in \mathcal{P}.$$

5.5.1. Beta-Binomial

Para un conjunto de datos $Y_1, \dots, Y_n$ i.i.d generados por una distribución binomial con parámetros n y θ , con probabilidad de éxito, $\mathbb{P}(Y_i = 1) = \theta$. Estimar la posterior de θ , $\mathbb{P}(\theta | y_1, \dots, y_n)$.

Modelo: Binomial(n, θ)

Prior: $\pi(\theta) = \text{Beta}(a, b)$

Posterior $\mathbb{P}(\theta | y_1, \dots, y_n) = \text{Beta}(?, ?)$

5.5.2. Normal-Normal

Tarea

5.5.3. Poisson-Gamma

Del libro concluimos:

Model: $Y_i | \theta \stackrel{\text{i.i.d.}}{\sim} \text{Poisson}(\theta), \quad i = 1, \dots, n$

Prior: $\theta \sim \text{Gamma}(a, b)$, esto es $\pi(\theta) = \frac{b^a}{\Gamma(a)} \theta^{a-1} e^{-b\theta}, \quad a, b > 0$

Posterior: (Gamma is conjugate)

$$\theta | \mathbf{y} \sim \text{Gamma}\left(a + \sum_{i=1}^n y_i, b + n\right)$$

Posterior mean and mode:

$$\mathbb{E}[\theta | \mathbf{y}] = \frac{a + \sum y_i}{b + n}, \quad \text{Mode}(\theta | \mathbf{y}) = \frac{a + \sum y_i - 1}{b + n} \quad (\text{if } a + \sum y_i > 1)$$

Posterior predictive distribution: (Negative Binomial)

$$\tilde{Y} | \mathbf{y} \sim \text{NegBin}\left(r = a + \sum y_i, p = \frac{b+n}{b+n+1}\right)$$

Posterior predictive mean and variance:

$$\mathbb{E}[\tilde{Y} | \mathbf{y}] = \frac{a + \sum y_i}{b + n}, \quad \text{Var}(\tilde{Y} | \mathbf{y}) = \frac{a + \sum y_i}{b + n} \left(1 + \frac{1}{b + n}\right)$$

Example (Birth Rates): Over the course of the 1990s, the General Social Survey gathered data on the educational attainment and number of children of 155 women. We compare women **without college degrees** (group 1) to those **with bachelor's or higher** (group 2) in terms of their numbers of children.

Data summary:

Group	n_g	$\sum y_{i,g}$	$\bar{y}_g$
Less than bachelor's	$n_1 = 111$	$\sum y_{i,1} = 217$	$\bar{y}_1 = 1.95$
Bachelor's or higher	$n_2 = 44$	$\sum y_{i,2} = 66$	$\bar{y}_2 = 1.50$

Model specification:

$$Y_{i,g} | \theta_g \stackrel{\text{i.i.d.}}{\sim} \text{Poisson}(\theta_g), \quad g = 1, 2$$

Prior:

$$\pi(\theta_g) = \text{Gamma}(a = 2, b = 1)$$

Tasks for students: Calcular las probabilidades posteriores de cada parámetro θ_1 y θ_2 . Comparar los gráficos de las funciones de distribución: prior y posteriores. Calcular la media y moda de las posteriores, junto con las estimaciones de 95 % de credibilidad. Interpreta los resultados.

R Code Template for Students:

```
# Data
n1 <- 111; sum1 <- 217
n2 <- 44; sum2 <- 66
a <- 2; b <- 1
```

```

# Posterior parameters
shape1 <- a + sum1; rate1 <- b + n1
shape2 <- a + sum2; rate2 <- b + n2

# Posterior means and modes
mean1 <- shape1 / rate1
mode1 <- (shape1 - 1) / rate1
mean2 <- shape2 / rate2
mode2 <- (shape2 - 1) / rate2

# 95% Credible intervals (Gamma)
CrI1 <- qgamma(c(0.025,0.975), shape=shape1, rate=rate1)
CrI2 <- qgamma(c(0.025,0.975), shape=shape2, rate=rate2)

# Posterior predictive distribution parameters
r1 <- shape1; p1 <- rate1/(rate1+1)
r2 <- shape2; p2 <- rate2/(rate2+1)

# Predictive mean and variance
pred_mean1 <- r1*(1-p1)/p1
pred_var1 <- r1*(1-p1)/p1^2

# Predictive 95% CrI (Negative Binomial)
# NB parameterization in R: size = r, prob = p
CrI_pred1 <- qnbinom(c(0.025,0.975), size=r1, prob=p1)
CrI_pred2 <- qnbinom(c(0.025,0.975), size=r2, prob=p2)

```

5.5.4. Exponencial - Gamma

5.5.5. Exponencial–y generalizaciones

Los modelos Binomiales, Poisson, Normal son distribuciones que pertenecen a la familia de distribución exponencial. La ventaja de trabajar con modelos exponenciales son:

- Para cada distribución de la familia exponencial **existe** una distribución *a priori* conjugada. Por lo que facilita trabajar con la distribución posterior.

- La inferencia depende solo de una estadística suficiente, como $\sum_{i=1}^n y_i$ para la distribución exponencial. Esto reduce los datos a una forma compacta sin perder información sobre el parámetro.

Ver formulas explicitas en el libro:

Las estudiaremos en detalle cuando estemos con regresion lineal/multilineal.

5.6. Distribución a priori no informativa

Definición 5.2 (A priori impropia). Una distribución a priori con función de densidad $f(\theta) \geq 0$ se llama *impropia* si

$$\int_{\Theta} f(\theta) d\theta = \infty$$

para parámetros continuos θ , o

$$\sum_{\theta \in \Theta} f(\theta) = \infty$$

para parámetros discretos θ .

ver ejemplos en el libro [2].

Definición 5.3 (A priori no informativa). Una *distribución priori no informativa* es aquella que busca minimizar la influencia de la información a priori sobre la inferencia bayesiana, de modo que los datos dominen el análisis. Muchas veces estas distribuciones son *impropias*, pero aún pueden generar distribuciones posteriores bien definidas si la información de los datos es suficiente.

Ejemplos comunes:

- **Uniforme:** Para un parámetro continuo $\theta \in (a, b)$:

$$f(\theta) = \frac{1}{b-a}, \quad \theta \in (a, b),$$

es propia si a y b son finitos, e impropia si el intervalo es infinito. Para un parámetro discreto con n posibles valores:

$$P(\theta = \theta_i) = \frac{1}{n}, \quad i = 1, \dots, n.$$

- **Proporcional a 1:** Para un parámetro continuo $\theta \in \mathbb{R}$:

$$f(\theta) \propto 1,$$

es impropia y se usa frecuentemente para parámetros sin límites conocidos.

Ver otros ejemplos en la referencia [2].

6. Intervalos de Credibilidad Bayesiano

6.1. Credible Interval (CrI)

Definición 6.1 (Credible Interval). Let θ be a parameter of interest with posterior distribution $p(\theta \mid Y = y)$. A $100 \times (1 - \alpha) \%$ **credible interval** (CrI) for θ is an interval $[l(y), u(y)]$ such that

$$\Pr(l(y) < \theta < u(y) \mid Y = y) = 1 - \alpha.$$

This means that, given the observed data y , there is $100 \times (1 - \alpha) \%$ posterior probability that θ lies inside the interval $[l(y), u(y)]$.

6.2. Quantile-based Credible Interval

A simple way to compute a credible interval is to use **posterior quantiles**. To construct a $100 \times (1 - \alpha) \%$ equal-tailed interval, find two numbers $\theta_{\alpha/2}$ and $\theta_{1-\alpha/2}$ such that:

1. $\Pr(\theta < \theta_{\alpha/2} \mid Y = y) = \alpha/2$,
2. $\Pr(\theta > \theta_{1-\alpha/2} \mid Y = y) = \alpha/2$.

Then, the equal-tailed credible interval is

$$[\theta_{\alpha/2}, \theta_{1-\alpha/2}].$$

This method is easy to implement from posterior samples: just take the $\alpha/2$ and $1 - \alpha/2$ quantiles.

6.3. Highest Density Interval (HDI)

When the posterior is skewed, the equal-tailed interval may not be the shortest interval containing $100 \times (1 - \alpha) \%$ of the probability. The **Highest Density Interval (HDI)** is defined as

$$\text{HDI}_{1-\alpha} = \{\theta : p(\theta | y) \geq c\},$$

where c is chosen so that

$$\Pr(\theta \in \text{HDI}_{1-\alpha} | y) = 1 - \alpha.$$

The HDI has two key properties:

- It contains $100 \times (1 - \alpha) \%$ of the posterior probability.
- Every point inside the HDI has higher posterior density than any point outside.

EL HDI: cubre todos los valores del parámetro más probables.

Ver libro pag 43, figura 3.5 y 3.6

Trabajar con los códigos del laboratorio 4.

7. El método de Monte Carlo

El método de Monte Carlo se basa en generar una **muestra aleatoria** de valores independientes de un parámetro de interés para aproximar su distribución y cualquier cantidad derivada de ella: $\theta_1 > \theta_1$, θ_1/θ_2 , $\text{máx}(\theta_1, \theta_2, \dots, \theta_n)$, etc.

De nuestro ejemplo anterior: estimar el número de hijos que en promedio tiene los grupos 1 y 2, nos gustaría calcular

$$\begin{aligned} \mathbb{P}(\theta_1 > \theta_2 | \text{Datos}_1, \text{Datos}_2) &= \int_0^\infty \int_0^{\theta_2} p(\theta_1, \theta_2 | \text{Data}_1, \text{Data}_2) d\theta_2 d\theta_1 \\ &= C \int_0^\infty \int_0^{\theta_2} \theta_1^{218} \theta_2^{67} e^{-112\theta_1 - 45\theta_2} d\theta_2 d\theta_1 \end{aligned}$$

para calcular por ejemplo el valor esperado $\theta_1 > \theta_1$. Usaremos el método de Monte Carlo, para no calcular las integrales resultantes.

7.1. Aproximación de la densidad Posterior

Si podemos generar S valores independientes de θ muestreados de la posterior:

$$\theta^{(1)}, \theta^{(2)}, \dots, \theta^{(S)} \stackrel{i.i.d.}{\sim} p(\theta \mid y_1, \dots, y_n)$$

entonces la distribución empírica de estas muestras:

$$\{\theta^{(1)}, \theta^{(2)}, \dots, \theta^{(S)}\}$$

es una **proximación Monte Carlo** de la verdadera distribución posterior $p(\theta \mid y_1, \dots, y_n)$. Esta aproximación converge en probabilidad hacia la verdadera distribución cuando $S \rightarrow \infty$.

7.2. Estimación de Cantidades de Interés

La **media posterior** de θ puede aproximarse como:

$$\widehat{\mathbb{E}}[\theta \mid y] = \hat{\theta} = \frac{1}{S} \sum_{s=1}^S \theta^{(s)}$$

La **Varianza Posterior** se estima usando la varianza muestral:

$$\widehat{\text{Var}}[\theta \mid y] = \hat{\sigma}^2 = \frac{1}{S-1} \sum_{s=1}^S (\theta^{(s)} - \hat{\theta})^2$$

La **distribución de la media muestral** $\hat{\theta}$ es aproximadamente normal para S grande (Teorema Central del Límite):

$$\hat{\theta} \approx N\left(\mathbb{E}[\theta \mid y], \frac{\sigma^2}{S}\right)$$

Por tanto, un **intervalo de confianza** de Monte Carlo del 95 % para la media posterior es:

$$[\hat{\theta} - 1.96\sqrt{\hat{\sigma}^2/S}, \hat{\theta} + 1.96\sqrt{\hat{\sigma}^2/S}]$$

Estas fórmulas permiten cuantificar tanto la estimación puntual de la media posterior como su incertidumbre debida al muestreo Monte Carlo.

Ejemplos: trabajar en el lab 5.

Estimación de probabilidades acumuladas con Monte Carlo

Sea $f(\theta \mid y)$ la distribución posterior de θ . Para calcular probabilidades del tipo

$$\mathbb{P}(\theta < 0.5 \mid y) = \int \mathbf{1}_{\{\theta < 0.5\}} f(\theta \mid y) d\theta,$$

basta con:

1. Simular $\theta^{(1)}, \dots, \theta^{(M)} \sim f(\theta \mid y)$.
2. Estimar la probabilidad como

$$\mathbb{P}(\theta < 0.5 \mid y) \approx \frac{1}{M} \sum_{m=1}^M \mathbf{1}_{\{\theta^{(m)} < 0.5\}}.$$

El promedio simple funciona porque todas las simulaciones son *igualmente probables*, al provenir de la distribución posterior, la integral es ahora bajo la medida de contar. Por la ley de los grandes números,

$$\frac{1}{M} \sum_{m=1}^M g(\theta^{(m)}) \rightarrow \mathbb{E}[g(\theta)] \quad \text{cuando } M \rightarrow \infty,$$

en este caso, $g(\theta)$ es la función indicadora.

Ejemplo bivariado

Si $(\theta_1, \theta_2) \sim f(\theta_1, \theta_2 \mid y)$ y queremos

$$\mathbb{P}(\theta_1 > \theta_2 \mid y),$$

entonces

$$\mathbb{P}(\theta_1 > \theta_2 \mid y) \approx \frac{1}{M} \sum_{m=1}^M \mathbf{1}_{\{\theta_1^{(m)} > \theta_2^{(m)}\}}.$$

8. El Algoritmo de Metropolis-Hastings con Caminata Aleatoria en MCMC

MCMC (Simulación de Monte Carlo con cadenas de Markov) son métodos que generan números aleatorios mediante una cadena de Markov diseñada para que, después de un tiempo, sus estados sigan la distribución de interés.

8.1. ¿Por qué necesitamos MCMC?

Imaginemos que queremos estudiar una distribución posterior compleja $\mathbb{P}(\theta|y)$ en el contexto bayesiano:

$$\mathbb{P}(\theta|y) = \frac{L(\theta)\pi(\theta)}{m(y)} \propto L(\theta)\pi(\theta) \quad (2)$$

El problema: No podemos muestrear directamente de esta distribución porque:

- La constante de normalización $m(y) = \int L(\theta)\pi(\theta)d\theta$ es intratable
- La forma de $\mathbb{P}(\theta|y)$ puede ser muy compleja (multimodal, alta dimensión, etc.)

La solución MCMC: Generar muestras $\{\theta^{(1)}, \theta^{(2)}, \dots, \theta^{(M)}\}$ que, aunque *dependientes*, aproximen muestras de $\mathbb{P}(\theta|y)$.

8.2. Fundamentos: Cadenas de Markov

Definición 8.1 (Cadena de Markov). Sea $\{\theta^{(m)}\}_{m \geq 0}$ una sucesión de variables aleatorias que toman valores en un conjunto S (espacio de estados).

$\{\theta^{(m)}\}$ es una **cadena de Markov** si cumple la *propiedad de Markov*:

$$P(\theta^{(m+1)} | \theta^{(m)}, \theta^{(m-1)}, \dots, \theta^{(0)}) = P(\theta^{(m+1)} | \theta^{(m)}) \quad (3)$$

Observación 8.1 (¿Qué significa esto?). El futuro de la cadena depende únicamente del presente, no del pasado. Es como tener “memoria corta”: para decidir dónde ir mañana, solo importa dónde estoy hoy, no cómo llegué aquí.

8.3. La Caminata Aleatoria: El Ejemplo Más Simple de Cadena de Markov

Ejemplo 8.1 (Caminata Aleatoria como Cadena de Markov). La **caminata aleatoria** es el ejemplo más intuitivo de cadena de Markov:

$$\theta^{(m+1)} = \theta^{(m)} + \epsilon^{(m+1)} \quad (4)$$

donde $\epsilon^{(m+1)} \sim q(\cdot)$ es independiente del pasado.

Verificación de la propiedad de Markov:

$$P(\theta^{(m+1)} | \theta^{(m)}, \dots, \theta^{(0)}) = P(\theta^{(m)} + \epsilon^{(m+1)} | \theta^{(m)}, \dots, \theta^{(0)}) \quad (5)$$

$$= P(\epsilon^{(m+1)}) = q(\theta^{(m+1)} - \theta^{(m)}) \quad (6)$$

$$= P(\theta^{(m+1)} | \theta^{(m)}) \quad (7)$$

¡Solo depende de $\theta^{(m)}$, no del historial completo!

8.4. Visualización de la Caminata Aleatoria




Figura 3: Ilustración de una caminata aleatoria explorando el espacio de parámetros

8.5. Tipos de Propuestas para la Caminata Aleatoria

8.5.1. Propuesta Normal Multivariada (La Más Común)

Ejemplo 8.2 (Caminata Aleatoria Normal). Para un parámetro $\theta \in \mathbb{R}^d$, la propuesta es:

$$\epsilon \sim \mathcal{N}(0, \Sigma) \quad (8)$$

$$\theta^* = \theta^{(m)} + \epsilon \sim \mathcal{N}(\theta^{(m)}, \Sigma) \quad (9)$$

donde Σ es la *matriz de covarianza de la propuesta*.

Observación 8.2 (¿Por qué Normal?).

- Es simétrica: $q(\theta^* | \theta^{(m)}) = q(\theta^{(m)} | \theta^*)$
- Permite pasos en todas las direcciones
- Fácil de implementar y ajustar (dar pasos pequeños, pero ocasionalmente dar saltos grandes)

El problema: Una caminata aleatoria pura explora el espacio de parámetros “sin dirección”. Para obtener muestras de $\mathbb{P}(\theta|y)$, necesitamos una caminata aleatoria “inteligente” que favorezca las regiones de alta probabilidad.

La solución: Metropolis-Hastings = Caminata aleatoria + Mecanismo de aceptación/rechazo

8.6. Idea Central del Algoritmo

Observación 8.3 (La Filosofía de Metropolis-Hastings). Queremos generar muestras que se distribuyan según $\mathbb{P}(\theta|y)$, pero no podemos muestrear directamente de esta distribución.

Estrategia:

1. Hacer una caminata aleatoria para explorar el espacio de parámetros
2. Usar un mecanismo inteligente de aceptación/rechazo que favorezca las regiones de alta probabilidad
3. Después de muchas iteraciones, las muestras aproximarán $\mathbb{P}(\theta|y)$

8.7. El Algoritmo de Metropolis-Hastings

Algorithm 1 Metropolis-Hastings: Un Paso Completo

- 1: **Estado actual:** $\theta^{(m)}$
- 2: **Proponer:** $\theta^* = \theta^{(m)} + \epsilon$ donde $\epsilon \sim \mathcal{N}(0, \Sigma)$
- 3: **Evaluar:** Calcular la *razón de densidades*

$$R = \frac{\mathbb{P}(\theta^*|y)}{\mathbb{P}(\theta^{(m)}|y)} = \frac{L(\theta^*)\pi(\theta^*)}{L(\theta^{(m)})\pi(\theta^{(m)})}$$

- 4: **Decidir:** Calcular probabilidad de aceptación

$$\alpha = \min(1, R)$$

- 5: **Lanzar moneda:** $U \sim \text{Uniforme}(0, 1)$
 - 6: **if** $U \leq \alpha$ **then**
 - 7: $\theta^{(m+1)} = \theta^*$ {¡Aceptar el paso!}
 - 8: **else**
 - 9: $\theta^{(m+1)} = \theta^{(m)}$ {Quedarse donde estamos}
 - 10: **end if**
-

8.8. ¿Por qué Funciona este Mecanismo?

Observación 8.4 (Lógica del Algoritmo).

- Si θ^* tiene **mayor densidad** que $\theta^{(m)}$: $R > 1 \Rightarrow \alpha = 1 \Rightarrow$ **siempre acepta**
- Si θ^* tiene **menor densidad** que $\theta^{(m)}$: $R < 1 \Rightarrow \alpha = R < 1 \Rightarrow$ acepta con probabilidad R
- Esto crea un *sesgo hacia regiones de alta densidad* sin rechazar completamente las de baja densidad

8.9. Consideraciones Numéricas Importantes

8.9.1. Trabajar en Escala Logarítmica

Se recomienda trabajar en escala logarítmica para garantizar la estabilidad numérica.

En lugar de calcular directamente

$$R = \frac{\mathbb{P}(\theta^* | y)}{\mathbb{P}(\theta^{(m)} | y)},$$

se evalúa

$$\log R = \ell(\theta^*) - \ell(\theta^{(m)}),$$

porque:

- **Evita problemas con números muy pequeños:** al trabajar con probabilidades, estas pueden ser tan cercanas a cero que la computadora las redondea a 0 (underflow).
- **Evita problemas con números muy grandes:** al calcular razones de probabilidades, los valores pueden crecer tanto que la computadora no los puede representar (overflow).
- **Mayor precisión:** los logaritmos permiten hacer los cálculos de manera más estable.

8.10. Algoritmo Completo

ver al libro con un algoritmo más general y wikipedia.

Algorithm 2 Algoritmo de Metropolis-Hastings Completo

Require: Función de log-densidad $\ell(\theta) = \log L(\theta) + \log \pi(\theta)$

Require: Matriz de propuesta Σ

Require: Valor inicial $\theta^{(0)}$

Require: Número de iteraciones M

Ensure: Vector para guardar las muestras $\{\theta^{(m)}\}_{m=1}^M$

Inicializar: $m = 0$, $\theta^{(0)}$, contadores de aceptación

while $m < M$ **do**

Paso 1 - Proponer:

 Generar $\epsilon \sim \mathcal{N}(0, \Sigma)$

 Calcular $\theta^* = \theta^{(m)} + \epsilon$

Paso 2 - Evaluar:

 Calcular $\ell^* = \ell(\theta^*)$ y $\ell^{(m)} = \ell(\theta^{(m)})$

 Calcular $\log R = \ell^* - \ell^{(m)}$

Paso 3 - Decidir:

 Si $\log R \geq 0$: $\alpha = 1$

 Si $\log R < 0$: $\alpha = \exp(\log R)$

Paso 4 - Aceptar/Rechazar:

 Generar $U \sim \text{Uniforme}(0, 1)$

if $U \leq \alpha$ **then**

$\theta^{(m+1)} = \theta^*$ {Aceptar}

 Incrementar contador de aceptación

else

$\theta^{(m+1)} = \theta^{(m)}$ {Rechazar}

end if

$m = m + 1$

end while

8.11. Calibración y Diagnósticos

8.11.1. El Papel Crucial de Σ

La matriz Σ controla *cómo* explora la caminata aleatoria. Por ejemplo, para Σ una matriz identidad con elementos en la diagonal σ_i :

Si σ_i es...	Entonces...	Resultado
Muy pequeña	Pasos muy pequeños	Alta aceptación, exploración lenta
Muy grande	Pasos muy grandes	Baja aceptación, muchos rechazos
Bien calibrada	Pasos apropiados	Exploración eficiente

8.11.2. Ajuste de la Matriz de Propuesta, Σ

- **Un parámetro:** Tasa óptima $\approx 45\%$
- **Múltiples parámetros:** Tasa óptima $\approx 23\%$

anexar referencias ???

8.11.3. Estrategia de Calibración

Algorithm 3 Calibración Adaptativa Durante Burn-in

- 1: Ejecutar N_{burn} iteraciones iniciales
 - 2: Cada N_{check} iteraciones:
 - 3: **if** Tasa de aceptación > 0.3 **then**
 - 4: $\Sigma = 1.1 \times \Sigma$ {Aumentar tamaño de paso}
 - 5: **else if** Tasa de aceptación < 0.15 **then**
 - 6: $\Sigma = 0.9 \times \Sigma$ {Reducir tamaño de paso}
 - 7: **end if**
-

8.11.4. Diagnosticar la Convergencia

Hacer gráficos de Trayectoria (Trace Plots) para Diagnosticar la Convergencia del algoritmo.

gráficos

8.12. Otras recomendaciones: transformaciones de parámetros

Observación 8.5 (Motivación para Transformaciones). La caminata aleatoria normal funciona mejor cuando:

- Los parámetros pueden tomar cualquier valor real
- La distribución posterior es aproximadamente normal
- No hay restricciones en el dominio

Por ejemplo, podemos usar los siguientes cambios de variable cuando sea necesario, por ejemplo:

$$\begin{aligned}\theta > 0 &\longrightarrow \eta = \log(\theta), \\ 0 < p < 1 &\longrightarrow \eta = \log\left(\frac{p}{1-p}\right).\end{aligned}$$

9. Regresión Lineal Bayesiana y la Familia Exponencial

Estos son comentarios generados por chagtp, luego los iré puliendo mientras nos acercamos a este tema.

1. Conexión Fundamental

La regresión lineal clásica puede verse como un caso especial de modelos de la familia exponencial.

En regresión lineal estándar asumimos:

$$Y_i \sim N(\mu_i, \sigma^2), \quad \mu_i = \beta_0 + \beta_1 X_{i1} + \cdots + \beta_p X_{ip}.$$

La distribución normal con varianza conocida pertenece a la familia exponencial, y la media μ_i se expresa como una combinación lineal de los predictores.

Implicación: Esto es la base de los **Modelos Lineales Generalizados (GLM)**:

Si la variable respuesta pertenece a la familia exponencial, su *parámetro natural* puede relacionarse con los predictores mediante una función lineal.

2. Exponencial y GLM

En un GLM especificamos:

1. La distribución de la respuesta Y (Normal, Poisson, Binomial, Exponencial...).
2. La función *link* $g(\cdot)$ que conecta el parámetro natural θ_i con los predictores:

$$g(\theta_i) = \beta_0 + \beta_1 X_{i1} + \cdots + \beta_p X_{ip}.$$

Ejemplos:

Respuesta Y	Distribución	Link / Modelo
Continua	Normal	Identidad $\rightarrow$ Regresión lineal clásica
Conteo	Poisson	Log $\rightarrow$ Regresión de Poisson
Tiempo de espera	Exponencial	Log $\rightarrow$ Regresión de tasas (supervivencia)

En el caso de la exponencial:

$$\lambda_i = \text{tasa de evento para el individuo } i, \quad \log \lambda_i = \beta_0 + \beta_1 X_{i1} + \cdots.$$

Esto se conoce como **regresión de tasas** (exponencial o de Poisson).

3. Por qué la Familia Exponencial es Clave en Regresión

Todos los GLM usan distribuciones de la familia exponencial (Normal, Poisson, Binomial, Exponencial...).

- El parámetro natural + la relación lineal permite **inferencia eficiente**.
- Existen **estadísticas suficientes simples**, como $\sum Y_i$.
- Usando un prior conjugado en el parámetro natural, la posterior puede ser:
 - Analíticamente tratable, o
 - Fácil de muestrear (si se usan métodos MCMC).

Regresión Bayesiana: Si usamos un prior normal para β , la posterior de β también es normal (caso de conjugación). Esto permite inferencia bayesiana exacta en regresión lineal.

Referencias

- [1] Donald L Cohn. *Measure theory*, volume 1. Springer, 2013.
- [2] Leonhard Held and Daniel Sabanés Bové. Likelihood and bayesian inference. *Statistics for Biology and Health. Springer, Berlin, Heidelberg*, 2020.
- [3] Paul G Hoel. Introduction to statistical theory. 1971.
- [4] Peter D. Hoff. *A First Course in Bayesian Statistical Methods*. Springer, 2009.
- [5] Luis Rincón. *Una introducción a la estadística inferencial*. Universidad Nacional Autónoma de México, México, 2019.